

Arquitetura de Dados: Topologia Híbrida e Engenharia de Pipeline

Especificação formal da arquitetura Medallion (Bronze, Silver e Gold) integrada ao Data Lakehouse com Apache Beam, Apache Hop, Parquet colunar Snappy, Quality Gate rigoroso e Governança automatizada no OpenMetadata.

- Data Lakehouse Medallion
- Arquitetura Híbrida (ETL + ELT)
- Parquet Hive (ano=YYYY/mes=MM)
- Apache Beam (DirectRunner & Spark)
- OpenMetadata (Metadata as Code)
- 98/98 Testes Homologados

1 Topologia do Pipeline em 5 Estágios com Contratos Rigorosos

O fluxo de dados foi projetado para assegurar separação estrita de responsabilidades, imutabilidade da camada raw, auditoria técnica contínua, linhagem completa e bloqueio automático em caso de falhas de qualidade:

ESTAGIO 1: FONTES Fontes Heterogeneas CSV, JSON e MongoDB	Origem Bruta Desacopiada Catálogo administrativo de cursos (CSV com 1.000 registros), logs de telemetria de interações (JSON com 1.000 eventos) e avaliações textuais livres extraídas do NoSQL (MongoDB com 1.000 documentos).	3 Fontes MULTI-FORMATO
ESTAGIO 2: BRONZE Cópia Raw Auditável Apache Hop + PostgreSQL	Ingestão Imutável com Metadados Técnicos (RF20) Carga 1:1 sem perdas de schema. Cada registro é enriquecido com campos de auditoria corporativa: <code>_origem</code> (nome do arquivo ou collection), <code>_ingestao_em</code> (timestamp ISO) e <code>_run_id</code> (UUID de execução).	3.000 LINHAS INGERIDAS
ESTAGIO 3: SILVER Curadoria & Quarentena Apache Hop + PyArrow	Higienização, Tipagem e Resolução MDM (RF20/RF30) Padronização de tipos (inteiros, decimais, timestamps), deduplicação e reconciliação de Golden Record. Registros anômalos são desviados para <code>quarentena.registros</code> (8 inconsistências isoladas com payload e motivo intactos).	3.000 / 8 SILVER / QUARENTENA
DATA LAKEHOUSE Parquet Hive Snappy PyArrow + Particionamento	Armazenamento Colunar de Alta Eficiência (RF24) Exportação estruturada no padrão Hive <code>ano=YYYY/mes=MM/part=0.parquet</code>. Redução comprovada de 72,16% no tamanho comparado ao CSV e 89,44% comparado ao JSON, viabilizando <code>partition pruning</code> e <code>pushdown</code> de colunas.	-72,16% COMPRESSÃO SNAPPY
ESTAGIO 4: GOLD Agregações Analíticas Apache Beam + Quality Gate	Cálculo Distribuído e Quality Gate Bloqueador (RF25/RF26/RF31) Pipeline Beam computa 64 agregações mensais em <code>kpi_mensais_categoria</code> e consolida 1.000 linhas em <code>desempenho conteudos</code>. A gravação é condicionada a 100% de aprovação nos testes críticos de qualidade.	1.064 REGISTROS GOLD
ESTAGIO 5: CONSUMO BI & Governança Superset + OpenMetadata	Visualização Executiva e Conformidade LGPD (RF16-RF18, RF27-RF33) Dashboards com cross-filtering e alertas automatizados no Superset. Catálogo com 13 tabelas, 4 Tiers, glossário formal, mascaramento LGPD e 19 arestas de linhagem rastreadas no OpenMetadata.	19 Arestas LINHAGEM COMPLETA

2 Classificação Arquitetural: A Abordagem Híbrida (ETL + ELT)

O projeto adota uma classificação formal de **Arquitetura Híbrida**, equilibrando segurança e saneamento antecipado na entrada com flexibilidade e poder de computação distribuída no core:

1. ETL na Borda (Ingestão no Apache Hop) Escopo: Da camada de Fontes Brutas até a Camada Silver. Justificativa Técnica: As fontes externas (CSV, JSON, MongoDB) possuem inconsistências severas, valores nulos e IDs corrompidos. Tratar os dados <i>antes</i> de gravá-los na Silver impede a contaminação do banco analítico e assegura que dados inválidos sejam desviados para a quarentena com rastreabilidade total.	2. ELT no Core (Lakehouse Parquet e Apache Beam) Escopo: Da Camada Silver até a Camada Gold. Justificativa Técnica: Os dados validados são exportados diretamente em formato bruto colunar particionado (Parquet). O motor analítico (Apache Beam e Apache Spark) carrega o dataset integral no lake e executa transformações, agrupamentos e cálculos de KPIs sob demanda, sem refazer a ingestão primária.
--	--

3 Matriz de Trade-offs e Decisões de Engenharia (RF19)

Cada escolha arquitetural foi fundamentada em testes comparativos e requisitos operacionais mensuráveis:

DIMENSÕES DE TRADE-OFF	DECISÃO IMPLEMENTADA	ALTERNATIVA REJEITADA	EVIDÊNCIA / JUSTIFICATIVA CONCRETA
Custo de Storage	Parquet particionado Snappy	JSON ou CSV bruto em disco	Redução comprovada de 72,16% vs CSV (36 KB vs 129 KB) e 89,44% vs JSON (36 KB vs 341 KB) no benchmark homologado.
Desempenho de Leitura	Pushdown de projeção e partição	Full Table Scans no banco relacional	Consultas analíticas leem somente colunas solicitadas, diminuindo o tempo de I/O de 2,26 ms (CSV) para 1,08 ms (Parquet).
Governança de Dados	OpenMetadata via API REST (Code)	Planilhas manuais ou Airflow pesado	13 entidades catalogadas com Owner 'admin', 4 Tiers, 4 termos no glossário e economia de mais de 3 GB de RAM ao dispensar containers lentos.
Qualidade de Dados	Quality Gate com bloqueio de Gold	Carga permissiva sem validação	5 dimensões testadas (Completeness, Validity, Uniqueness, Consistency e Referentiality); bloqueio de 75% comprovado em cenários de teste anômalos.
Reprocessamento	Particionamento Hive idempotente	Carga incremental monolítica	Reprocessar um mês específico exige reescrever somente o diretório <code>ano=YYYY/mes=MM</code> , sem impacto ou lock nas partições dos demais meses.

4 Evolução Arquitetural: Do Legado (Desafio 1) ao Lakehouse (Desafio 2)

DESAFIO PRÁTICO 1 (LEGADO) Scripts Desacoplados Execuções pontuais de scripts Python via linha de comando, sem orquestração visual, sem metadados de auditoria em camadas, sem isolamento de quarentena e sem catálogo central de dados.	DESAFIO PRÁTICO 2 (ATUAL) Pipeline Lakehouse Integrado Orquestração visual reproduzível no Apache Hop, esteira distribuída em Apache Beam, armazenamento colunar Parquet particionado, bloqueio automático por Quality Gate e governança ponta a ponta no OpenMetadata.
--	---